

Causal Machine Learning

• Ignacio Peletier | Senior Data Scientist @ Busuu

Un poco sobre mi

Industria de video @ Epic Labs & Haivision:

- Clasificación de imágenes y detección de objetos
- Optimización de rutas de video
- Detección de manipulaciones en videos

Pricing @ Cabify & MoonPay:

- Algoritmos de precio dinámico
- Monetización, new user pricing, descuentos y rewards

Aprendizaje de idiomas @ Busuu:

- Algoritmos adaptativos para el aprendizaje
- LLMs aplicados al aprendizaje de idiomas

Análisis estadístico y diseño de experimentos

(También me gusta la escalada, el yoga y el ajedrez!)

MIGUEL SERRANO



IGNACIO PELETIER

EN QUÉ PIENSAN LOS ROBOTS

BIENVENIDOS A LA ERA DE
LA INTELIGENCIA ARTIFICIAL:

TODO LO QUE CAMBIARÁ Y TODO
LO QUE PERMANECERÁ

LA GUÍA DEFINITIVA PARA ENTENDER LA DISRUCCIÓN QUE VIENE

DEUSTO

CAUSAL ML

Definición

Predictive ML vs Causal ML

Experimentación

Quasi experimentos

CATE: Meta-learners


**La Inferencia Causal trata
de predecir los efectos de
nuestras intervenciones.**

Richard McElreath


Definiciones

Definiciones

- **Science Direct:** La inferencia causal es el término utilizado para el proceso de determinar si una asociación observada refleja realmente una relación de causa y efecto.
- **Wikipedia:** La inferencia causal es el proceso de determinar el efecto independiente y real de un fenómeno particular que forma parte de un sistema más amplio.





Por qué necesitamos la Inferencia Causal?



La paradoja de Simpson

- Fenómeno en el que una tendencia aparece en varios grupos de datos, pero desaparece o se invierte cuando los grupos se combinan.



Uno de los ejemplos más conocidos de la paradoja de Simpson proviene de un estudio sobre el sesgo de género en las admisiones a programas de posgrado de la Universidad de California, Berkeley. Las cifras de admisión para el otoño de 1973 mostraron que los hombres que solicitaban ingreso tenían más probabilidades de ser admitidos que las mujeres, y la diferencia era tan grande que era poco probable que se debiera al azar.

	All		Men		Women	
	Applicants	Admitted	Applicants	Admitted	Applicants	Admitted
Total	12,763	41%	8,442	44%	4,321	35%

Sin embargo, al tener en cuenta la información sobre los departamentos a los que se solicitaba ingreso, los diferentes porcentajes de rechazo revelan la distinta dificultad de ser admitido en cada departamento, y al mismo tiempo se mostró que las mujeres tendían a postularse a departamentos más competitivos con menores tasas de admisión, incluso entre los solicitantes calificados (como en el departamento de inglés), mientras que los hombres tendían a postularse a departamentos menos competitivos con mayores tasas de admisión (como en el departamento de ingeniería). Los datos combinados y corregidos mostraron un "pequeño pero estadísticamente significativo sesgo a favor de las mujeres".

	All		Men		Women	
	Applicants	Admitted	Applicants	Admitted	Applicants	Admitted
Total	12,763	41%	8,442	44%	4,321	35%

Department	All		Men		Women	
	Applicants	Admitted	Applicants	Admitted	Applicants	Admitted
A	933	64%	825	62%	108	82%
B	585	63%	560	63%	25	68%
C	918	35%	325	37%	593	34%
D	792	34%	417	33%	375	35%
E	584	25%	191	28%	393	24%
F	714	6%	373	6%	341	7%
Total	4526	39%	2691	45%	1835	30%

Legend:

 greater percentage of successful applicants than the other gender


 greater number of applicants than the other gender

bold – the two 'most applied for' departments for each gender

Experimentación

A/B Testing


- **Definición:** Método para comparar dos versiones (A y B) de un producto o campaña para ver cuál funciona mejor.
- **Objetivo:** Medir el impacto de un cambio específico en el comportamiento de los usuarios.
- **Cómo funciona:**
 - Se divide **aleatoriamente** a los usuarios en dos grupos.
 - Grupo A recibe la versión original.
 - Grupo B recibe la versión modificada.
- **Ventaja:** Decisiones basadas en datos reales, no suposiciones.



Quasi Experimentos


Regression Discontinuity

- Útil cuando hay corte natural en una variable
- Ejemplo: efecto de la edad legal para ingesta de alcohol en la frecuencia de consumo




Difference-in-difference

- Útil cuando se aplica un tratamiento a uno de dos grupos paralelos
- Ejemplo: lanzamos nuevo producto en iOS pero no en Android



Control Sintético


- Útil cuando se aplica un tratamiento a uno de varios grupos
- Ejemplo: aumento de impuestos sobre el tabaco en California (proposition 99)




Predictive ML vs Causal ML

Predictive ML vs Causal ML

- Estamos en un escenario de toma de decisiones: queremos tomar decisiones óptimas.
- Usando Machine Learning (ML) podemos hacer una predicción y planificar en consecuencia:
 - **Banca:** 95% de probabilidad de que esta persona haga un impago.
 - **Mantenimiento:** los sensores indican necesidad de mantenimiento.
 - **Pronóstico del tiempo:** hay un 25% de probabilidad de que nieve.
- Se necesita ML causal cuando nuestras acciones son variables de entrada y, por lo tanto, cambian el resultado que estamos prediciendo:
 - Pricing: ¿qué pasaría si bajara el precio en un 10%?
 - Marketing: ¿qué pasaría si duplicase mi presupuesto en TikTok?
 - Recomendaciones: ¿qué pasaría si en lugar de recomendar A, recomendamos B?




Volvamos a Nic Cage




Number of people who drowned by falling into a pool
correlates with
Films Nicolas Cage appeared in

Correlation: 66.6% ($r=0.666004$)



Causal ML

- Los diagramas causales pueden complicarse mucho.
- Cuando contruidos propiamente, nos permiten computar **contrafactuales** y responder a preguntas del tipo: ¿Y si...?



Scenario	Decisions		Outcomes	
	Rider Coupons	Driver Bonuses	Rides	Revenue
Aggressive Growth	High	High	+8%	+4%
Balanced Growth	Low	Medium	+3%	+5%
No action	Status Quo	Status Quo	0%	0%


Meta-learners

- Hay veces que el “efecto medio” se queda corto.
 - Quizás queramos personalizar en función de características grupales o individuales.
- Este es el área de los meta-learners, árboles causales y otros algoritmos.
- Imaginad que lanzamos un experimento de marketing:

Tipo de email	Conversión
Email por defecto	10%
Hombres	12%
Mujeres	15%


S-Learner

- Single Learner.
- Es simplemente cualquier modelo de ML que incluye el tratamiento y otras variables.



T-Learner

- Twin Learner.
- Son dos modelos de ML:
 - Cada uno es entrenado con datos de una variante.



Referencias

- Causal Inference for Statistics: A Primer
- Statistical Rethinking
- [Spurious Correlations Web](#)
- Causal Inference and Discovery in python
- [Causal Inference for the Brave and True](#)